

R para datos de biologging

Modelos ocultos de Markov en R

Rocío Joo

Nov.-Dic. 2020

Objetivos de esta unidad


- Introducir los modelos ocultos de Markov
- Implementar estos modelos en R con `momentuHMM`
 - Modelo simple con 3 estados
 - Modelo con 4 estados con restricciones en las transiciones
 - Modelo con covariables condicionando las transiciones y variables observadas
- Referencias sobre más teoría y práctica

Modelos ocultos de Markov

¿Qué son?



Modelos ocultos de Markov

¿Qué son?




Modelos ocultos de Markov


¿Qué son?



Modelos ocultos de Markov




Modelos ocultos de Markov




- Proceso de Markov escondido y subyacente $\{S_t\}$:
 $P(S_t = s_t | S_{t-1} = s_{t-1}) = P(S_t = j | S_{t-1} = i) = \gamma_{ij}$

Modelos ocultos de Markov



- Proceso de Markov escondido y subyacente $\{S_t\}$:
 $P(S_t = s_t | S_{t-1} = s_{t-1}) = P(S_t = j | S_{t-1} = i) = \gamma_{ij}$
- Proceso de observación dependiente del estado $\{Z_t\}$:
 $P(Z_t = z_t | S_t = s_t)$

Modelos ocultos de Markov



- Proceso de Markov escondido y subyacente $\{S_t\}$:
 $P(S_t = s_t | S_{t-1} = s_{t-1}) = P(S_t = j | S_{t-1} = i) = \gamma_{ij}$
- Proceso de observación dependiente del estado $\{Z_t\}$:
 $P(Z_t = z_t | S_t = s_t)$
- t es discreto

Trabajaremos con datos de Michelot et al. 2017.

- Southern elephant seal (*Mirounga leonina*)
- Tracks Argos de 15 individuos (8 hembras adultas y 7 machos sub-adultos) en Kerguelen.
- Pre-procesamiento de datos con modelos espacio-estado.

Los datos están en el GD: ./R-Rocío/05-HMM/Datos/

Trabajaremos con datos de Michelot et al. 2017.

- Southern elephant seal (*Mirounga leonina*)
- Tracks Argos de 15 individuos (8 hembras adultas y 7 machos sub-adultos) en Kerguelen.
- Pre-procesamiento de datos con modelos espacio-estado.

Los datos están en el GD: ./R-Rocío/05-HMM/Datos/

```
path_data <- "./data/"  
trackData <- read.csv(paste0(path_data, "seal_tracks.csv"))  
head(trackData)
```

```
##      ID      lon       lat           date  
## 1  1 70.60946 -49.60737 2014-02-11 10:34:58  
## 2  1 70.82908 -50.08287 2014-02-11 20:10:58  
## 3  1 70.90029 -50.32835 2014-02-12 05:46:58  
## 4  1 70.85766 -50.54746 2014-02-12 15:22:58  
## 5  1 70.63792 -50.90529 2014-02-13 00:58:58  
## 6  1 70.48480 -50.99666 2014-02-13 10:34:58
```

```
str(trackData)
```

```
## 'data.frame':    7353 obs. of  4 variables:  
##   $ ID  : int  1 1 1 1 1 1 1 1 1 1 ...  
##   $ lon : num  70.6 70.8 70.9 70.9 70.6 ...  
##   $ lat : num  -49.6 -50.1 -50.3 -50.5 -50.9 ...  
##   $ date: Factor w/ 7353 levels "2013-02-13 22:27:43",...: 44
```

```
str(trackData)

## 'data.frame':    7353 obs. of  4 variables:
## $ ID  : int  1 1 1 1 1 1 1 1 1 ...
## $ lon : num  70.6 70.8 70.9 70.9 70.6 ...
## $ lat : num  -49.6 -50.1 -50.3 -50.5 -50.9 ...
## $ date: Factor w/ 7353 levels "2013-02-13 22:27:43",...
```

Los pasos de tiempo son regulares.

```
dates <- as.character(trackData[,4])
time_dif <- diff.Date(as.POSIXct(dates, tz = "GMT"))
head(time_dif)
```

```
## Time differences in hours
## [1] 9.6 9.6 9.6 9.6 9.6 9.6
```

Preparando los datos

Intentaremos identificar estados escondidos a partir de los desplazamientos (step) y el cambio de ángulo (angle).

`momentuHMM` permite calcularlos fácilmente con `prepData`

Preparando los datos

Intentaremos identificar estados escondidos a partir de los desplazamientos (step) y el cambio de ángulo (angle).


momentuHMM permite calcularlos fácilmente con prepData

```
library(momentuHMM)
data <- prepData(trackData, type = "LL",
                  coordNames = c("lon", "lat"))
head(data)
```

| | ID | step | angle | date | x | y |
|------|----|----------|------------|---------------------|----------|-------|
| ## 1 | 1 | 55.19656 | NA | 2014-02-11 10:34:58 | 70.60946 | -49.6 |
| ## 2 | 1 | 27.77600 | -0.1051839 | 2014-02-11 20:10:58 | 70.82908 | -50.0 |
| ## 3 | 1 | 24.56027 | -0.3069499 | 2014-02-12 05:46:58 | 70.90029 | -50.3 |
| ## 4 | 1 | 42.72315 | -0.2468352 | 2014-02-12 15:22:58 | 70.85766 | -50.5 |
| ## 5 | 1 | 14.80219 | -0.4426067 | 2014-02-13 00:58:58 | 70.63792 | -50.9 |
| ## 6 | 1 | 27.87312 | 0.9141237 | 2014-02-13 10:34:58 | 70.48480 | -50.9 |

Se pueden explorar visualmente los datos del nuevo objeto `momentuHMM` con `plot`

```
plot(x=data, compact=TRUE, ask=FALSE)
```



Modelo oculto de Markov de 3 estados

- Se espera identificar 3 estados como proxies de: trayecto (T), búsqueda (B) y forrajeo (F)
- Variables observadas: step y angle

Parámetros del modelo:

Matriz de (probabilidades de) transición:

$$\Gamma = \begin{bmatrix} & \text{Trayecto} & \text{Busqueda} & \text{Forrajeo} \\ \text{Trayecto} & \gamma_{TT} & \gamma_{TB} & \gamma_{TF} \\ \text{Busqueda} & \gamma_{BT} & \gamma_{BB} & \gamma_{BF} \\ \text{Forrajeo} & \gamma_{FT} & \gamma_{FB} & \gamma_{FF} \end{bmatrix}$$

Probabilidades iniciales:

$$\Pi = [\pi_T, \pi_B, \pi_F]$$

8 parámetros a estimar

Modelo oculto de Markov de 3 estados

Parámetros del modelo:

L: step (desplazamiento)


$$L_t | S_t = s_t \sim \text{Gamma}(\text{shape}, \text{scale})$$

Valores iniciales:

$$L_t | S_t = T \sim \text{Gamma}(40, 10)$$

$$L_t | S_t = B \sim \text{Gamma}(20, 8)$$

$$L_t | S_t = F \sim \text{Gamma}(8, 5)$$



Modelo oculto de Markov de 3 estados

Parámetros del modelo:

Θ : angle (cambio de ángulo)

$\Theta_t | S_t = s_t \sim VM(\text{location}, \text{concentration})$


Valores iniciales:

$\Theta_t | S_t = T \sim VM(-0.001, 7)$

$\Theta_t | S_t = B \sim VM(0, 4)$

$\Theta_t | S_t = F \sim VM(\pi, 0.1)$

Son 12 parámetros a estimar para el modelo de observación. 20 en total.



Modelo oculto de Markov de 3 estados

Ahora en R:

Valores iniciales para los parámetros en el modelo

```
stateNames <- c("trayecto", "busqueda", "forrajeo")
shape_0 <- c(40,20,8)
scale_0 <- c(10,8,5)
stepPar0 <- c(shape_0,scale_0)
location_0 <- c(-0.001,0,3.14)
concentration_0 <- c(7,4,0.1)
anglePar0 <- c(location_0,concentration_0)
```

Modelo oculto de Markov de 3 estados

Ahora ajustando el modelo

```
m1 <- fitHMM(data=data, nbStates=3,
               dist=list(step="gamma", angle="vm"),
               Par0=list(step=stepPar0, angle=anglePar0),
               estAngleMean = list(angle=TRUE),
               stateNames = stateNames)

print(m1) #estimaciones
```

Modelo oculto de Markov de 3 estados

```
## Value of the maximum log-likelihood: -33840.15
##
##
## step parameters:
## -----
##          trayecto  busqueda forrajeo
## mean  38.914015 18.690249 7.748900
## sd    9.941105  7.934075 5.052587
##
## angle parameters:
## -----
##          trayecto  busqueda forrajeo
## mean      -0.005191108 0.01653228 3.0754817
## concentration 12.187982113 2.73019365 0.1529828
##
## Regression coeffs for the transition probabilities:
## -----
```

Modelo oculto de Markov de 3 estados

Matriz de transición:

$$\Gamma = \begin{bmatrix} & \textit{Trayecto} & \textit{Busqueda} & \textit{Forrajeo} \\ \textit{Trayecto} & 0.97 & 0.03 & 0.00 \\ \textit{Busqueda} & 0.03 & 0.87 & 0.10 \\ \textit{Forrajeo} & 0.00 & 0.05 & 0.95 \end{bmatrix}$$

Probabilidades iniciales:

$$\Pi = [0.84, 0.11, 0.05]$$

Modelo oculto de Markov de 3 estados

Reconstruyendo la secuencia de estados:

El algoritmo Viterbi:

$$\arg \max_{S_0=s_0, \dots, S_t=s_t} P(S_0 = s_0, \dots, S_t = s_t \mid Z_0 = z_0, \dots, Z_t = z_t)$$

En R:

```
states.1 <- as.factor(viterbi(m1)) # reconstrucción de estados
head(states.1)

## [1] 1 1 1 1 2 2
## Levels: 1 2 3

prop.table(table(states.1))



## states.1
##          1              2              3
## 0.2623419 0.2560860 0.4815721
```

Modelo oculto de Markov de 3 estados

Salidas gráficas

```
plot(m1, plotCI = TRUE, plotTracks=FALSE)
```

```
## Decoding state sequence... DONE
```



Modelo oculto de Markov de 3 estados

¿Cómo validar el modelo?

Modelo oculto de Markov de 3 estados

¿Cómo validar el modelo? Diagnóstico de supuestos, simulaciones, sentido ecológico


Modelo oculto de Markov de 3 estados

¿Cómo validar el modelo? Diagnóstico de supuestos, simulaciones, sentido ecológico

Diagnóstico de supuestos:

`plotPR(m1)`

Computing pseudo-residuals... DONE



Desafío

2 opciones:

- ① Utilizar sus propios datos.
- ② Utilizar los datos de albatroz de Clay et al. 2020
 - Ajustar un HMM a los datos y hacer un diagnóstico de residuos.
 - Hacer gráficos
 - Interpretar los resultados.
 - Dentro del GD: CURSO R-biologging/R-Rocío/05-HMM/Actividades/ ,
 - Crear una carpeta ahí con sus iniciales, e.g. "CI-CZ"
 - Un google doc con sus nombres
 - Un script R
 - Archivo(s) de gráfico (o reporte Rmarkdown con R + salidas)
 - Si prefieren hacer el trabajo individualmente, dentro de la carpeta del grupo, creen subcarpetas por persona

Modelo oculto de Markov de 4 estados

- Se espera identificar 4 estados como proxies de: salida (S), búsqueda (B), forrajeo (F) y entrada (E)
- No todas las transiciones son posibles
- Variables observadas: step y angle

El modelo de observación es casi el mismo, sólo añadimos otro estado.

Empecemos por ahí.

Modelo oculto de Markov de 4 estados

Parámetros del modelo:

L: step (desplazamiento)

$$L_t | S_t = s_t \sim \text{Gamma}(\text{shape}, \text{scale})$$


Valores iniciales:

$$L_t | S_t = S \sim \text{Gamma}(40, 10)$$

$$L_t | S_t = B \sim \text{Gamma}(20, 8)$$

$$L_t | S_t = F \sim \text{Gamma}(8, 5)$$

$$L_t | S_t = E \sim \text{Gamma}(40, 10)$$



Modelo oculto de Markov de 4 estados

Parámetros del modelo:

Θ : angle (cambio de ángulo)

$\Theta_t | S_t = s_t \sim VM(\text{location}, \text{concentration})$

Valores iniciales:


$\Theta_t | S_t = S \sim VM(-0.001, 7)$

$\Theta_t | S_t = B \sim VM(0, 4)$

$\Theta_t | S_t = F \sim VM(\pi, 0.1)$

$\Theta_t | S_t = E \sim VM(-0.001, 7)$

Son 16 parámetros a estimar para el modelo de observación.



Modelo oculto de Markov de 4 estados

Ahora en R:

Valores iniciales para los parámetros en el modelo

```
stateNames <- c("salida","busqueda","forrajeo","entrada")
shape_0 <- c(40,20,8,40)
scale_0 <- c(10,8,5,10)
stepPar0 <- c(shape_0,scale_0)
location_0 <- c(-0.001,0,3.14,-0.001)
concentration_0 <- c(7,4,0.1,7)
anglePar0 <- c(location_0,concentration_0)
```

Modelo oculto de Markov de 4 estados

No todas las transiciones son posibles

| | <i>Salida</i> | <i>Busqueda</i> | <i>Forrajeo</i> | <i>Entrada</i> |
|-----------------|---------------|-----------------|-----------------|----------------|
| <i>Salida</i> | | | 0 | 0 |
| <i>Busqueda</i> | 0 | | | |
| <i>Forrajeo</i> | 0 | | | 0 |
| <i>Entrada</i> | 0 | 0 | 0 | |

Modelo oculto de Markov de 4 estados

No todas las transiciones son posibles

| | <i>Salida</i> | <i>Busqueda</i> | <i>Forrajeo</i> | <i>Entrada</i> |
|-----------------|---------------|-----------------|-----------------|----------------|
| <i>Salida</i> | γ_{SS} | γ_{SB} | 0 | 0 |
| <i>Busqueda</i> | 0 | γ_{BB} | γ_{BF} | γ_{BE} |
| <i>Forrajeo</i> | 0 | γ_{FB} | γ_{FF} | 0 |
| <i>Entrada</i> | 0 | 0 | 0 | 1 |

Modelo oculto de Markov de 4 estados

No todas las transiciones son posibles

| | <i>Salida</i> | <i>Busqueda</i> | <i>Forrajeo</i> | <i>Entrada</i> |
|-----------------|---------------|-----------------|-----------------|----------------|
| <i>Salida</i> | γ_{SS} | γ_{SB} | 0 | 0 |
| <i>Busqueda</i> | 0 | γ_{BB} | γ_{BF} | γ_{BE} |
| <i>Forrajeo</i> | 0 | γ_{FB} | γ_{FF} | 0 |
| <i>Entrada</i> | 0 | 0 | 0 | 1 |

En momento HMM, $\gamma_{ij} = \text{logit}^{-1}(\beta X)$; X: covariables

Si no hay covariables, entonces $\gamma_{ij} = \text{logit}^{-1}(\beta_0) = \frac{1}{1 + \exp(-\beta_0)}$

Entonces, para $\gamma_{ij} \approx 0$, β_0 : un número negativo bien grande; e.g. -100

Para este ejemplo:

```
beta_M2=c(NA,-100,-100, -100, NA, NA, -100, NA, -100, -100,  
-100, -100)
```

Modelo oculto de Markov de 4 estados

Ahora ajustando el modelo

```
m2 <- fitHMM(data=data, nbStates=4,  
               dist=list(step="gamma", angle="vm"),  
               Par0=list(step=stepPar0, angle=anglePar0),  
               estAngleMean = list(angle=TRUE),  
               fixPar=list(beta=beta_M2),  
               stateNames = stateNames)
```

```
print(m2) #estimaciones
```

Modelo oculto de Markov de 4 estados

```
## Value of the maximum log-likelihood: -34046.67
##
##
## step parameters:
## -----
##          salida  busqueda forrajeo  entrada
## mean  39.63980 19.773845 7.892547 37.55535
## sd    11.48888  8.438879 5.157049 11.06350
##
## angle parameters:
## -----
##          salida  busqueda forrajeo      entrada
## mean       -0.01061419 0.01304199 3.0426369 7.164037e-04
## concentration 10.35182617 3.08073292 0.1253199 1.039474e+01
##
## Regression coeffs for the transition probabilities:
## -----
```

Modelo oculto de Markov de 4 estados

A partir de los β estimados se calcula la matriz de transición:

| | Salida | Busqueda | Forrajeo | Entrada |
|----------|--------|----------|----------|---------|
| Salida | 0.99 | 0.01 | 0 | 0 |
| Busqueda | 0 | 0.89 | 0.10 | 0.01 |
| Forrajeo | 0 | 0.05 | 0.95 | 0 |
| Entrada | 0 | 0 | 0 | 1 |

Probabilidades iniciales:

$$\Pi = [1.00, 0, 0, 0]$$

Modelo oculto de Markov de 4 estados

Reconstruyendo la secuencia de estados:

```
states.2 <- as.factor(viterbi(m2)) # reconstrucción de estados
head(states.2)

## [1] 1 1 1 1 1 1
## Levels: 1 2 3 4

prop.table(table(states.2))


## states.2
##      1          2          3          4
## 0.1365429 0.2461580 0.4920441 0.1252550
```

Modelo oculto de Markov de 4 estados

Salidas gráficas

```
plot(m2, plotCI = TRUE, plotTracks=FALSE)
```

```
## Decoding state sequence... DONE
```




Modelo oculto de Markov de 4 estados

Diagnóstico de supuestos:

`plotPR(m2)`

Computing pseudo-residuals... DONE



Modelo oculto de Markov de 4 estados con covariables

- Se espera identificar 4 estados como proxies de: salida (S), búsqueda (B), forrajeo (F) y entrada (E)
- No todas las transiciones son posibles
- Variables observadas: step y angle
- Algunas probabilidades de transición dependen de covariables
- El modelo observado también depende de covariables
- Covariables: distancia y dirección respecto a la colonia, tiempo desde la salida de la colonia

Empecemos con el cálculo de las covariables.

Modelo oculto de Markov de 4 estados con covariables

Utilizando `centers` en `prepData`, se calcula distancia a ese o esos centros. En este caso, la colonia.

```
center <- matrix(c(70,-49), nrow=1, dimnames=list("colony"))
data <- prepData(data=trackData, type="LL", centers=center,
                  coordNames = c("lon", "lat"))
head(data[,c(1:3,7,8)])
```

| | ID | step | angle | colony.dist | colony.angle |
|----|----|----------|------------|-------------|--------------|
| ## | 1 | 55.19656 | NA | 80.79235 | 0.5847407 |
| ## | 2 | 27.77600 | -0.1051839 | 134.55555 | -2.9626223 |
| ## | 3 | 24.56027 | -0.3069499 | 161.40565 | -2.9047384 |
| ## | 4 | 42.72315 | -0.2468352 | 182.86506 | -2.6678926 |
| ## | 5 | 14.80219 | -0.4426067 | 216.80945 | -2.5543702 |
| ## | 6 | 27.87312 | 0.9141237 | 224.79045 | -2.1702936 |

Modelo oculto de Markov de 4 estados con covariables

Asumiendo que sale de la colonia desde el inicio del seguimiento:

```
time <- NULL # objeto vacío
for(id in unique(data$ID)) {
  nbSubObs <- sum(data$ID==id) # número de obs con ese ID
  time <- c(time, ((1:nbSubObs)-1)*9.6) # tiempo en horas
}
data$time <- time

data[1:3,c(1,4,7:9)]
```

| | ID | date | colony.dist | colony.angle | time |
|----|----|---------------------|-------------|--------------|------|
| ## | 1 | 2014-02-11 10:34:58 | 80.79235 | 0.5847407 | 0.0 |
| ## | 2 | 2014-02-11 20:10:58 | 134.55555 | -2.9626223 | 9.6 |
| ## | 3 | 2014-02-12 05:46:58 | 161.40565 | -2.9047384 | 19.2 |

Modelo oculto de Markov de 4 estados con covariables

No todas las transiciones son posibles

| | S | B | F | E |
|---|---------------|---------------|---------------|---------------|
| S | γ_{SS} | γ_{SB} | 0 | 0 |
| B | 0 | γ_{BB} | γ_{BF} | γ_{BE} |
| F | 0 | γ_{FB} | γ_{FF} | 0 |
| E | 0 | 0 | 0 | 1 |

Modelo oculto de Markov de 4 estados con covariables

No todas las transiciones son posibles

| | S | B | F | E |
|---|---------------|---------------|---------------|---------------|
| S | γ_{SS} | γ_{SB} | 0 | 0 |
| B | 0 | γ_{BB} | γ_{BF} | γ_{BE} |
| F | 0 | γ_{FB} | γ_{FF} | 0 |
| E | 0 | 0 | 0 | 1 |

Michelot et al (2017): '(...) Animals often make fast trips away from the colony and tend to switch into other movement modes once they have reached foraging grounds'

Modelo oculto de Markov de 4 estados con covariables

No todas las transiciones son posibles

| | S | B | F | E |
|---|---------------|---------------|---------------|---------------|
| S | γ_{SS} | γ_{SB} | 0 | 0 |
| B | 0 | γ_{BB} | γ_{BF} | γ_{BE} |
| F | 0 | γ_{FB} | γ_{FF} | 0 |
| E | 0 | 0 | 0 | 1 |

Michelot et al (2017): '(...) Animals often make fast trips away from the colony and tend to switch into other movement modes once they have reached foraging grounds'

Entonces, la distancia a la colonia tendría un efecto sobre la probabilidad de transición entre salida y búsqueda

Modelo oculto de Markov de 4 estados con covariables

No todas las transiciones son posibles

| | S | B | F | E |
|---|---------------|---------------|---------------|---------------|
| S | γ_{SS} | γ_{SB} | 0 | 0 |
| B | 0 | γ_{BB} | γ_{BF} | γ_{BE} |
| F | 0 | γ_{FB} | γ_{FF} | 0 |
| E | 0 | 0 | 0 | 1 |

Michelot et al (2017): '(...) Animals often make fast trips away from the colony and tend to switch into other movement modes once they have reached foraging grounds'

Entonces, la distancia a la colonia tendría un efecto sobre la probabilidad de transición entre salida y búsqueda

$$\gamma_{ij} = \text{logit}^{-1}(\beta X)$$

Modelo oculto de Markov de 4 estados con covariables

No todas las transiciones son posibles

| | S | B | F | E |
|---|---------------|---------------|---------------|---------------|
| S | γ_{SS} | γ_{SB} | 0 | 0 |
| B | 0 | γ_{BB} | γ_{BF} | γ_{BE} |
| F | 0 | γ_{FB} | γ_{FF} | 0 |
| E | 0 | 0 | 0 | 1 |

Michelot et al (2017): '(...) Animals often make fast trips away from the colony and tend to switch into other movement modes once they have reached foraging grounds'

Entonces, la distancia a la colonia tendría un efecto sobre la probabilidad de transición entre salida y búsqueda

$$\gamma_{ij} = \text{logit}^{-1}(\beta X) \rightarrow \gamma_{SB}^{(t)} = \text{logit}^{-1}(\beta_0^{(SB)} + \beta_1^{(SB)} d_t)$$

d_t : distancia del individuo a la colonia en el tiempo t

Modelo oculto de Markov de 4 estados con covariables

No todas las transiciones son posibles

| | S | B | F | E |
|---|---------------|---------------|---------------|---------------|
| S | γ_{SS} | γ_{SB} | 0 | 0 |
| B | 0 | γ_{BB} | γ_{BF} | γ_{BE} |
| F | 0 | γ_{FB} | γ_{FF} | 0 |
| E | 0 | 0 | 0 | 1 |

Michelot et al (2017): '(...) Animals often make fast trips away from the colony and tend to switch into other movement modes once they have reached foraging grounds'

Entonces, la distancia a la colonia tendría un efecto sobre la probabilidad de transición entre salida y búsqueda

$$\gamma_{ij} = \text{logit}^{-1}(\beta X) \rightarrow \gamma_{SB}^{(t)} = \text{logit}^{-1}(\beta_0^{(SB)} + \beta_1^{(SB)} d_t)$$

d_t : distancia del individuo a la colonia en el tiempo t

$$\gamma_{SB}^{(t)} = \frac{\exp(\beta_0^{(SB)} + \beta_1^{(SB)} d_t)}{1 + \exp(\beta_0^{(SB)} + \beta_1^{(SB)} d_t)}$$

Modelo oculto de Markov de 4 estados con covariables

No todas las transiciones son posibles

| | S | B | F | E |
|---|---------------|---------------|---------------|---------------|
| S | γ_{SS} | γ_{SB} | 0 | 0 |
| B | 0 | γ_{BB} | γ_{BF} | γ_{BE} |
| F | 0 | γ_{FB} | γ_{FF} | 0 |
| E | 0 | 0 | 0 | 1 |

Modelo oculto de Markov de 4 estados con covariables

No todas las transiciones son posibles

| | S | B | F | E | |
|---|---------------|---------------|---------------|---------------|----------------------------------|
| S | γ_{SS} | γ_{SB} | 0 | 0 | Michelot et al (2017): '... time |
| B | 0 | γ_{BB} | γ_{BF} | γ_{BE} | constraints to go back to the |
| F | 0 | γ_{FB} | γ_{FF} | 0 | colony ...' |
| E | 0 | 0 | 0 | 1 | |

Modelo oculto de Markov de 4 estados con covariables

No todas las transiciones son posibles

| | S | B | F | E | |
|---|---------------|---------------|---------------|---------------|----------------------------------|
| S | γ_{SS} | γ_{SB} | 0 | 0 | Michelot et al (2017): '... time |
| B | 0 | γ_{BB} | γ_{BF} | γ_{BE} | constraints to go back to the |
| F | 0 | γ_{FB} | γ_{FF} | 0 | colony ...' |
| E | 0 | 0 | 0 | 1 | |

$$\gamma_{BE}^{(t)} = \frac{\exp(\beta_0^{(BE)} + \beta_1^{(BE)}(t - t_0))}{1 + \exp(\beta_0^{(BE)} + \beta_1^{(BE)}(t - t_0)) + \exp(\beta_0^{BF})}$$

$$\gamma_{BF}^{(t)} = \frac{\exp(\beta_0^{(BF)})}{1 + \exp(\beta_0^{(BE)} + \beta_1^{(BE)}(t - t_0)) + \exp(\beta_0^{BF})}$$

Modelo oculto de Markov de 4 estados con covariables

Parámetros del modelo:

¿Qué parámetros β estimar? NA para aquellos, 0 los que no, y -100 para las transiciones que no deberían ocurrir

| | SB | SF | SE | BS | BF | BE | FS | FB | FE | ES | EB | EF |
|-----------|----|----|----|----|----|----|----|----|----|----|----|----|
| β_0 | | | | | | | | | | | | |
| d_t | | | | | | | | | | | | |
| $t - t_0$ | | | | | | | | | | | | |

```
beta <- matrix(c(NA,-100,-100,-100,NA,NA,-100,NA,-100,
                  -100,-100,-100,
                  NA,0,0,0,0,0,0,0,0,0,0,0,
                  0,0,0,0,0,NA,0,0,0,0,0,0),
                  nrow=3,byrow=TRUE)
```

Modelo oculto de Markov de 4 estados con covariables

Parámetros del modelo:

¿Qué parámetros β estimar? NA para aquellos, 0 los que no, y -100 para las transiciones que no deberían ocurrir

```
beta <- matrix(c(NA,-100,-100,-100,NA,NA,-100,NA,-100,
                  -100,-100,-100,
                  NA,0,0,0,0,0,0,0,0,0,0,0,
                  0,0,0,0,0,NA,0,0,0,0,0,0),
                  nrow=3,byrow=TRUE)
```

```
formula <- ~ colony.dist + time
```

Modelo oculto de Markov de 4 estados con covariables

Parámetros del modelo:

Vamos a modelar la salida y la entrada como BRWs, con repulsión desde la colonia para la salida, y atracción hacia la colonia durante la entrada.

En momentoHMM, esto se expresa así:

```
angleFormula <- ~ state1(colony.angle) +  
  state4(colony.angle)  
fixPar <- list(angle=c(-100,100,NA,NA,NA,NA),beta=beta)
```

- 4 parámetros de concentración para estimar
- -100 para localización: en promedio, dirección opuesta a la colonia
- 100 para localización: en promedio, en dirección hacia la colonia

Esto se desprende de la regresión circular en donde

$$\mu = \text{atan2}(\sin(\text{angle})\beta, 1 + \cos(\text{angle})\beta)$$

Modelo oculto de Markov de 4 estados con covariables

Parámetros del modelo:

La distribución Gamma se utilizará para el desplazamiento (step).

En lugar de empezar de cero, usaremos los valores estimados por el modelo anterior como valores iniciales para ajustar este modelo.

```
m2 <- fitHMM(data=data, nbStates=4,
                dist=list(step="gamma", angle="vm"),
                Par0=list(step=stepPar0, angle=anglePar0),
                estAngleMean = list(angle=TRUE),
                fixPar=list(beta=beta_M2),
                stateNames = stateNames)

Par0 <- getPar0(model=m2, nbStates=4,
                 DM=list(angle=list(mean=angleFormula,
                                     concentration=~1)),
                 estAngleMean=list(angle=TRUE),
                 circularAngleMean=list(angle=TRUE),
                 formula=formula)
```

Modelo oculto de Markov de 4 estados con covariables

Ahora ajustamos el modelo

```
m3 <- fitHMM(data=data, nbStates=4,
               dist=list(step="gamma", angle="vm"),
               Par0=list(step=Par0$Par$step,
                         angle=Par0$Par$angle),
               beta0=Par0$beta, fixPar=fixPar, formula=formula,
               DM=list(angle=list(mean=angleFormula,
                                  concentration=~1)),
               estAngleMean=list(angle=TRUE),
               circularAngleMean=list(angle=TRUE),
               stateNames = stateNames)
```

Modelo oculto de Markov de 4 estados con covariables

Reconstruyendo la secuencia de estados:

```
states.3 <- as.factor(viterbi(m3))  
prop.table(table(states.3))
```


```
## states.3  
##      1          2          3          4  
## 0.1262070 0.2430301 0.5161159 0.1146471
```

Modelo oculto de Markov de 4 estados con covariables

Diagnóstico de supuestos:

`plotPR(m3)`

`## Computing pseudo-residuals... DONE`



Otras cosas que se pueden hacer

- Introducir un centro de actividad dinámico
- Otros modelos más complicados con límites en los parámetros
- Métodos de imputación de datos (e.g. usando `crawl`)
- Introducir efectos aleatorios

Desafío

¿Pueden mejorar sus modelos anteriores?

- Ajustar un HMM a los datos y hacer un diagnóstico de residuos.
- Hacer gráficos
- Interpretar los resultados.
- - Dentro del GD: CURSO R-biologging/R-Rocío/05-HMM/Actividades/,
 - Crear una carpeta ahí con sus iniciales, e.g. "CI-CZ"
 - Un google doc con sus nombres
 - Un script R
 - Archivo(s) de gráfico (o reporte Rmarkdown con R + salidas)
 - Si prefieren hacer el trabajo individualmente, dentro de la carpeta del grupo, creen subcarpetas por persona

Bibliografía

Para preparar esta unidad se utilizó:

Material de:

- Michelot Théo, Langrock Roland, Bestley Sophie, Jonsen Ian D., Photopoulou Theoni, & Patterson Toby A. (2017). [Estimation and simulation of foraging trips in land-based marine predators](#). Ecology, 98(7), 1932–1944.
- McClintock, B.T. and Michelot, T. (2018) [momentuHMM: R package for generalized hidden Markov models of animal movement](#). Methods in Ecology and Evolution 9(6): 1518-1530.

Datos de:

- Michelot Théo, Langrock Roland, Bestley Sophie, Jonsen Ian D., Photopoulou Theoni, & Patterson Toby A. (2017). [Estimation and simulation of foraging trips in land-based marine predators](#). Ecology, 98(7), 1932–1944.

Bibliografía

Más:

- McClintock, B. T., Langrock, R., Gimenez, O., Cam, E., Borchers, D. L., Glennie, R., & Patterson, T. A. (2020). [Uncovering ecological state dynamics with hidden Markov models](#). Ecology Letters, 23(12), 1878–1903.